


Patrones invisibles de movilidad

¿Dónde y cuándo posicionar conductores?

Información, segmentos y perfiles para la operación de UrbanMove.

Decisiones de cobertura, capacidad y control de anomalías.

Objetivo: reducir esperas sin sobreofertar. El impacto se valida en operación.



32.000 recogidas de entrenamiento • vista central de NYC. Densidad sobre polígonos locales; no es un mapa de espera.

La necesidad de UrbanMove

“Tenemos más de un millón de viajes históricos y no sabemos qué hacer con ellos más allá de mirar promedios. Necesitamos entender qué tan predecible es la demanda en cada zona y momento del día, qué perfiles de viaje existen realmente (no los que nosotros imaginamos), y dónde debemos posicionar conductores para minimizar tiempos de espera sin sobre-ofertar en zonas de baja demanda.”

— Dirección de Operaciones, UrbanMove

Fuente: Proyecto Retador — Patrones Invisibles: Información, Incertidumbre y Movilidad Urbana. Escenario profesional, sección 1.1.

Una muestra común; variables para cada pregunta

1.458.644

Viajes originales · 11 variables

40.000

Muestra aleatoria tras depuración · semilla 42


Bloque	Variables y propósito
Base / R4	Hora/día; borough/distrito; minutos; Haversine y velocidad.
R1	Zonas 8×8; tipo de día; franjas; niveles diarios; anomalías.
R2	Distancia, duración y hora estandarizadas; etiquetas de grupo.
R3	Fin de semana; log(1+x); responsabilidades y perfil dominante.

Duración y destino: diagnóstico retrospectivo, no información de despacho.

Muestreo para reducir costo computacional.
Depuración de pasajeros, duración, desplazamiento nulo y duplicados.

Fuentes: cuatro cuadernos. Haversine no mide el recorrido vial. Contrastes: proveedor $p=0,6325$; pasajeros $p=0,4363$ (no prueban equivalencia).

La hora reduce apenas 1,93 % de la incertidumbre



0,04134 bits

Información mutua entre hora y zona de origen

$$I(T; Z) = H(Z) - H(Z|T)$$

$$2,14624 - 2,10490 = 0,04134.$$


$I(\text{Hora}; \text{destino}) = 0,05698$ bits/viaje: asociación retrospectiva, no información disponible al despacho.

Base: 32.000 viajes; partición cronológica 80/20. Cuadrícula ajustada solo con entrenamiento.

La hora, por sí sola, aporta poca información para ubicar conductores.

Fuente: metricas_resumen.csv, rol 1. $H(Z) = -\sum p(z) \log_2 p(z)$; $0,04134 / 2,14624 = 1,93 \%$.

El pico cambia entre laborables y fines de semana



PICOS OBSERVADOS

20:00 / 18:00

Laborables / fines de semana


70,49 % de viajes laborales.
29,51 % de fin de semana.

$H(\text{Nivel de demanda diaria} \mid \text{tipo de día}) = 1,5584 \text{ bits/día}$,
sobre tres niveles definidos por terciles.

La incertidumbre espacial es mayor en la mañana (07-09): **2,165 bits**, frente a **1,880** en el valle (00-05). Considerar cobertura más flexible en esa franja.

Fuente: entrenamiento del rol 1 y métricas exportadas. Cada curva suma 100 % dentro de su tipo de día; no representa vehículos requeridos.

Los perfiles espaciales son cercanos, no idénticos



Soporte común de 64 celdas; suavizado de Laplace $\alpha = 1$. KL es dirigida y no tiene unidades monetarias.

ENTROPÍA CRUZADA

$$H(P, Q) = H(P) + D_{\text{KL}}(P \| Q)$$

Fin de semana usando el perfil laboral:
 $2,15056 + 0,01835 = 2,16892$ bits.

JENSEN · PROBABILIDADES REALES

$$E[\log_2 P(Z)] = -2,1462$$


$$\log_2 E[P(Z)] = -1,7163$$

Se verifica la desigualdad; margen: **0,4299 bits.**

KL baja: poca discrepancia espacial. Los picos horarios orientan los relevos.

Fuente: kl_direccional.csv, entropia_cruzada.csv y jensen.csv. Entropía cruzada inversa: laboral con referencia fin de semana = 2,21959 bits.

Log-sum-exp combina probabilidades reales



Zona R05C02: 15.096 de 32.000 recogidas. Cálculo reproducido a partir del dataset.

MEZCLA LABORAL / FIN DE SEMANA

Pesos: (0,70491; 0,29509).

$P(z \mid \text{tipo})$: (0,45542; 0,51075).

$$a_k = \ln w_k + \ln p(z|k)$$

$$\text{LSE}(a) = m + \ln \sum_k e^{a_k - m}$$

$a = (-1,13622; -1,89234)$.

$\text{LSE}(a) = -0,751306$.

$\exp(\text{LSE}) = 0,47175$.

Puente hacia EM: normalizar con $\gamma_k = \exp(a_k - \text{LSE}(a))$ evita perder precisión. Con $(-1000, -1001, -999)$, $\text{LSE} = -998,5924$; el cálculo directo devuelve $-\infty$.

Fuente: nueva verificación reproducible en generar_graficas.py y prueba de estabilidad del rol 1. Logaritmos naturales en LSE.

Tres columnas, una misma escala

COLUMNAS UTILIZADAS

distancia_haversine_km km

trip_duration minutos

horas_pickup 0–23

ESTANDARIZACIÓN

$$z = \frac{x - \mu}{\sigma}$$

StandardScaler: centra cada variable y la lleva a desviación estándar 1.


Evita que las unidades dominen la distancia.

40.000 viajes para K-means y DBSCAN.

Las franjas horarias y los boroughs describen los grupos; no son columnas del ajuste.

Fuente: cuaderno del rol 2, selección de columnas y estandarización.

Primero evaluar; después interpretar



k	Inercia ↓	Silhouette ↑	Davies-Bouldin ↓	Calinski-Harabasz ↑
2	82.864,0	0,9440	0,0982	17.925,3
4	29.213,9	0,4692	0,5874	41.431,1

k = 4 permite una segmentación más detallada. k = 2 obtiene mejor Silhouette: la elección combina métricas e interpretación.

Curvas del cuaderno redibujadas desde su CSV. Búsqueda k=2...14; 10 reinicios; semilla 42.

Cuatro grupos con comportamientos distintos

GRUPO 0 · 21.467 VIAJES

53,67 %

Recogidas de **tarde y noche**.
Fuerte presencia de **Manhattan → Manhattan**.

GRUPO 1 · 42 VIAJES

0,105 %

Viajes que **cruzan de fecha**.
Predomina el proveedor 2; duraciones extremas.

GRUPO 2 · 15.302 VIAJES

38,26 %

Mayor presencia de **madrugada y mañana**.
Viajes que comienzan y terminan el mismo día.


GRUPO 3 · 3.189 VIAJES

7,97 %

Distancias **>5 km**; predominan duraciones **>20 min**.
Presencia importante de orígenes en **Queens**.

Fuente: tamaños y caracterización del cuaderno del rol 2. Se conservan sus etiquetas originales; porcentajes redondeados.

El radio controla la detección de viajes aislados



$\epsilon = 0.9$ `min_samples = 10`

Métrica	Valor
Silhouette ↑	0,9453
Davies–Bouldin ↓	0,0596
Calinski–Harabasz ↑	10.492,0
Ruido	0,105 % · 42 viajes

Cola de k-distancia del cuaderno, redibujada.

Con $\epsilon = 0,5$ hay **83** casos de ruido; con $\epsilon = 1,3$, **12**. Se elige 0,9 considerando la curva y esta sensibilidad.

Fuente: cuaderno y CSV del rol 2. Métricas calculadas sin ruido; no se comparan directamente con K-means, que incluye todos los viajes.

Dos grupos densos y una categoría de ruido

GRUPO 0

39.935

99,84 % de los viajes

Patrón mayoritario.

Duraciones **inferiores a 2 horas**.

Sin una diferenciación fuerte en el resto de variables.

GRUPO 1

23

0,0575 % de los viajes

Duraciones **>23 horas**.

Manhattan → Manhattan; cruzan de fecha.

Distancia $\leq 5,9$ km y velocidad muy baja.

RUIDO · ETIQUETA -1

42

0,105 % de los viajes

Distancias de **0,11 a 114 km**.

Velocidades cercanas a 0 y hasta aproximadamente 70 km/h.

Duraciones elevadas.

Fuente: grupos y análisis de ruido del cuaderno del rol 2. Ruido no equivale a error confirmado.

Marcar, investigar y convertir hallazgos en reglas

01 / ASIGNAR FLAG

Conservar el viaje y marcar ruido, duración extrema o incoherencia.

02 / INVESTIGAR

Revisar el recorrido, el taxímetro y los registros de la plataforma.


03 / ESTABLECER REGLAS

Validar criterios de distancia, duración y velocidad; aplicarlos a nuevos viajes.

No eliminar automáticamente. Separar errores confirmados de viajes reales atípicos y conservar la trazabilidad.

Propuesta del cuaderno del rol 2. Los umbrales de las reglas requieren validación operativa antes de generalizarse.

Cuatro perfiles: una decisión de parsimonia



39.875

Viajes tras retirar 125 extremos • 0,3125 %

Hora, fin de semana y $\log(1+x)$ de duración, distancia y velocidad. Estandarización posterior.

Covarianzas completas; barrido de $K = 2...8$.

BIC K=4: -203.271,2.


BIC K=8: -283.550,9.

El menor BIC del barrido está en K=8.


K = 4 por interpretación; el menor BIC del barrido está en K = 8.

Fuente: salidas guardadas del rol 3. Filtro 3×IQR en variables logarítmicas. El barrido y el ajuste final usan inicializaciones diferentes.

El punto de partida cambia el ajuste obtenido



Seguimiento: 40 pasos, 0 descensos. Δ final=0,00417 $> 10^{-4}$; no converge con ese umbral. Ejecución distinta del modelo final.




Gráfica original: 10 semillas por método, $n_{\text{init}}=1$. Los puntos muestran las ejecuciones individuales.

Modelo final: k-means++, 20 reinicios, 27 iteraciones. Convergíó; log-verosimilitud media 2,7406.

Fuente: rol 3 y convergencia_reproducida.csv. Criterio del seguimiento: $|\Delta \text{log-verosimilitud media}| < 10^{-4}$; modelo final: tolerancia de sklearn 10^{-3} .

Duración, distancia y velocidad distinguen los perfiles



0 • Largos laborales
21,78 % · 24,67 min

1 • Estándar laborales
30,54 % · 11,77 min


2 • Cortos laborales
19,01 % · 7,09 min

3 • Fin de semana
28,68 % · 12,78 min

Los largos concentran aproximadamente **38,43 % del tiempo ocupado**: su carga supera su cuota de viajes.

Gráfica original del rol 3: cajas por perfil dominante, sin mostrar atípicos. Cuotas y medias de las tarjetas: ponderadas por responsabilidades.

Dos decisiones que conectan espacio, hora y carga



Las 7 celdas principales reúnen 98,45 % de las recogidas de entrenamiento. La cuadrícula es gruesa: refinar antes de decidir puntos exactos.

Fuentes: rol 1, segmentación rol 2 y perfiles rol 3. Son prioridades para probar; la cantidad óptima de conductores requiere información de oferta y espera.

1. POSICIONAMIENTO Y RELEVOS

Pilotar en **7 de 64 celdas**. Revisar relevos a las **20:00 laborales y 18:00 fines de semana**.

R1: concentración y picos. R2: patrones regulares y extremos.

2. CAPACIDAD SEGÚN TIEMPO OCUPADO

Perfil largo: **21,78 % de viajes y 38,43 % del tiempo ocupado**. Usar ambos en escenarios de capacidad.

R3: carga probabilística. R2: duración y distancia. Las cuotas no equivalen a número de vehículos.

Decidir, auditar y medir el resultado

3. CONTROL DE ANOMALÍAS

42 casos de ruido DBSCAN y el grupo de duraciones >23 horas.

Contrastar con los **125 extremos del GMM** y las banderas del rol 1.

Conservar registros; validar reglas de revisión.

Medir errores confirmados, tiempos de espera y utilización en el piloto.

LÍMITES DEL ANÁLISIS

Muestra: 40.000 de 1.458.644 viajes (2,74 %). Los patrones poco frecuentes pueden estar subrepresentados.

Distancia Haversine: usa solo origen y destino; no mide el recorrido vial real.

Velocidad estimada: Haversine / duración. No incorpora la trayectoria ni las variaciones de velocidad durante el viaje.

Las recomendaciones son hipótesis operativas, no mejoras ya demostradas.

Fuentes: NYC Taxi Trip Duration • Kaggle Repositorio del equipo • cuadernos y resultados.